

LongEmbed: Mở rộng mô hình embedding cho truy xuất ngữ cảnh dài

Hứa Mạnh Tân, Nguyễn Tấn Tài, Nguyễn Nhật Thành

Tóm tắt và slide bởi Tài Nguyễn

Dựa trên arXiv:2404.12096

Mục lục

- 1 Động lực
- 2 Đóng góp chính
- 3 LONGEMBED
- 4 Phương pháp mở rộng
- 5 Thí nghiệm
- 6 Ablation và phân tích sâu
- 7 Kết luận và hướng phát triển

Tại sao cần embedding cho ngữ cảnh dài?

- Nhiều ứng dụng thực tế (wikipedia dài, transcript cuộc họp, báo cáo chính phủ) cần truy xuất thông tin trong văn bản dài.
- Hầu hết embedding model hiện tại chỉ hỗ trợ 512 token (hoặc vài k tokens) — giới hạn khả năng truy xuất.
- Huấn luyện mô hình embedding dài từ đầu tốn kém (ví dụ hàng chục GPU A100).
- Câu hỏi: có thể mở rộng ngữ cảnh cho mô hình embedding hiện có mà không huấn luyện lại toàn bộ không?

Đóng góp chính của paper

- Giới thiệu benchmark LONGEMBED (2 tác vụ tổng hợp + 4 tác vụ thực tế) để đánh giá truy xuất trong ngữ cảnh dài.
- Thăm dò các chiến lược mở rộng cửa sổ ngữ cảnh không cần huấn luyện (training-free) và một số fine-tune bảo toàn hành vi ngắn.
- So sánh APE vs RoPE: phát hiện RoPE có lợi thế rõ ràng khi mở rộng ngữ cảnh.
- Phát hành mã nguồn và các mô hình tiền huấn luyện mở rộng (E5Base-4k, E5-RoPEBase).

LONGEMBED — Tổng quan

- Kết hợp 2 tác vụ tổng hợp (có kiểm soát độ dài) và 4 tác vụ thực tế (văn bản dài, thông tin mục tiêu phân tán).
- Mục tiêu: đo khả năng phát hiện thông tin mục tiêu khi độ dài đầu vào tăng lên (tới 32,768 tokens).
- Các bộ thử nghiệm: Needle, Passkey (synthetic); SummScreenFD, NarrativeQA, QMSum, GovReport, ... (real-world dạng rút trích/truy vấn).

Thiết kế tác vụ và tiêu chuẩn đánh giá

- Tác vụ truy xuất: cho truy vấn, tìm passage chứa thông tin mục tiêu.
- Độ dài đánh giá: từ 256 lên tới 32,768 tokens (các mốc: .25k, .5k, 1k, 2k, 4k, 8k, 16k, 32k).
- Metric: Accuracy trên passkey, các metric tiêu chuẩn cho từng bộ dữ liệu (ví dụ ROUGE, F1 cho một số tác vụ tóm tắt/QA khi phù hợp).

Chiến lược mở rộng (overview)

- 1 Parallel Context Windows (PCW) - chia input thành nhiều cửa sổ song song.
- 2 Reorganize Position IDs - sắp xếp lại vị trí để tránh tràn bộ mã hóa vị trí.
- 3 Position Interpolation - nội suy vị trí (NTK, PI, YaRN, Resonance RoPE).
- 4 Fine-tune bảo toàn hành vi ngắn (simulate long samples, preserve short-context behaviour).

Parallel Context Windows (PCW)

- Ý tưởng: chia văn bản dài thành nhiều đoạn ngắn, encode riêng rồi kết hợp vector (ví dụ pooling/aggregation).
- Ưu: training-free, dễ triển khai.
- Nhược: mất bối cảnh toàn cục liên tục; cần chiến lược aggregation phù hợp.

Position Reorganization & Interpolation

- Reorganize Position IDs: thay đổi assignment của position ids để "trick" mô hình chấp nhận index lớn hơn.
- Position Interpolation (NTK-aware, PI): nội suy embedding vị trí hiện có để mở rộng dải vị trí liên tục; NTK-aware điều chỉnh để giữ tính tương tự tần số.
- RoPE (rotary position encoding) cho thấy lợi thế: việc nội suy/scale dễ thao tác hơn so với APE.

Thiết lập thí nghiệm

- Các mô hình được thử: E5, E5-RoPE, E5-Mistral, Contriever, GTE, BGE-M3, Ada-002, ...
- Các biến thể: +Tuning (fine-tune dài bảo toàn), +SE (SelfExtend), +NTK (NTK-aware interpolation).
- Độ dài huấn luyện/đánh giá: thử nhiều mức; mục tiêu mở rộng tới 32k.

Kết quả chính (tóm tắt)

- Mô hình gốc sụt giảm mạnh khi độ dài tăng — room for improvement.
- Chiến lược training-free như position reorg / interpolation cải thiện đáng kể.
- RoPE-based models (ví dụ E5-RoPE, E5-Mistral + NTK) đạt tiến bộ lớn, thậm chí tới 32k với độ chính xác cao trên Passkey.
- Fine-tune bảo toàn (simulate long inputs) giúp APE-based models cải thiện nhưng hạn chế hơn RoPE.

Biểu đồ & phân tích




Figure 1: (a) Overview of the LONGEMBED benchmark. (b) Performance of current embedding models on passkey retrieval, with evaluation length ranging from 256 to 32,768¹. \blacktriangle / \blacklozenge denotes embedding models with 512 / $\geq 4k$ context. The greener a cell is, the higher retrieval accuracy this model achieves on the corresponding evaluation length. (c) Effects of context window extension methods on E5, E5-RoPE, E5-Mistral, measured by improvements of Avg. Scores on LONGEMBED. SE / NTK is short for SelfExtend / NTK-Aware Interpolation.

Hình: *

Figure 1: Hiệu năng theo độ dài ngữ cảnh.

- Kiểm tra từng thành phần: interpolation method, reorganize id scheme, pooling strategy cho PCW.
- Kết luận: NTK-aware interpolation + RoPE mang lại lợi ích lớn nhất; pooling strategy ảnh hưởng đến hiệu năng tổng thể.

- Một số phương pháp vẫn cần fine-tune để đạt hiệu năng tối ưu trên APE-models.
- Tài nguyên tính toán khi fine-tune với ngữ cảnh dài vẫn là thách thức.
- Độ dài siêu dài (hàng trăm k tokens) có thể yêu cầu kỹ thuật bổ sung (compression, memory transformer).

- Có thể mở rộng ngữ cảnh cho embedding models hiện tại bằng phương pháp plug-and-play và một số fine-tune bảo toàn.
- RoPE cho thấy lợi thế rõ rệt khi mở rộng vị trí — gợi ý cho thiết kế embedding model tương lai.
- LONGEMBED là benchmark hữu ích để thúc đẩy nghiên cứu trong lĩnh vực embedding ngữ cảnh dài.

- Bản gốc: "LongEmbed: Extending Embedding Models for Long Context Retrieval", arXiv:2404.12096.
- Code: tác giả công bố GitHub (LongEmbed repository).
- Một số tham khảo liên quan: NTK interpolation, SelfExtend, Resonance RoPE.